

GRAPH ATTENTION NETWORKS

Petar Veličković*

Department of Computer Science and Technology
University of Cambridge
petar.velickovic@cst.cam.ac.uk

Guillem Cucurull*

Centre de Visió per Computador, UAB
gucurull@gmail.com

Arantxa Casanova*

Centre de Visió per Computador, UAB
ar.casanova.8@gmail.com

Adriana Romero

Montréal Institute for Learning Algorithms
adriana.romero.soriano@umontreal.ca

Pietro Liò

Department of Computer Science and Technology
University of Cambridge
pietro.lio@cst.cam.ac.uk



Yoshua Bengio

Montréal Institute for Learning Algorithms
yoshua.umontreal@gmail.com

Introduction

Grid vs Graph 구조 데이터

- CNN은 데이터가 **grid** 형태로 표현되는 분야에 성공적이었음
(image classification, semantic segmentation, machine translation 등)
- 하지만 **graph** 구조로 표현되어야 하는 분야들도 존재함
(3D Meshes, social networks, telecommunication networks, biological networks, brain connections, 등)





Graph에 대한 Neural Network 기반 접근법



- **Spectral Representation**
 - Graph Laplacian의 고유값 분해를 계산 후 Fourier domain 내 합성곱 연산
 - intense한 연산과 non-spatially localized한 필터 생성
 - 세부적인 구조와 피처의 특성을 반영하는데 특화
 - 새로운 구조 그래프나 새로운 노드에 대한 정보 반영 어려움
- **Non-spectral & Spatial Representation**
 - 합성곱을 Graph에 직접적으로 적용하고, 인접(spatially close)한 이웃 그룹에 대해 연산을 수행(e.g. GraphSAGE)
 - GraphSAGE는 스케일이 큰 Large Graph에 대해 효과적인 접근법으로 평가됨

Introduction

Spectral Representation



Spatial Representation




Introduction

Node Classification

- 그래프 내의 노드의 라벨(Node Type, Feature)을 분류
 - Node Type은 노드가 속한 범주나 클래스
(ex. 소셜 네트워크 그래프: 사람, 게시물, 댓글 등)
 - Node Feature는 노드를 설명하는 추가적인 정보나 속성 의미
(ex. 소셜 네트워크 그래프 “사람” 노드의 특성: 나이, 성별, 관심사 등)

Attention vs. Self-Attention Mechanism

- **Attention**
 - 모델이 입력 데이터의 특정 부분에 집중할 수 있도록 각 부분에 다른 가중치를 할당하는 방법
 - ex. 기계 번역에서 타겟 문장의 각 단어를 번역할 때 소스 문장의 관련 단어에 집중할 수 있도록 함
- **Self-Attention**
 - 입력 데이터가 자기 자신에게 집중하는 **Attention**의 특수한 경우로, 동일한 시퀀스로 서로 다른 위치 간의 **Attention** 점수를 계산
 - ex. 자연어처리에서는 Self-Attention이 문장 내의 각 단어가 다른 단어에 집중할 수 있도록 하여 단어 간의 관계를 포착



Introduction

Graph Attention Networks(GAT) 모델

- 그래프 구조의 데이터에 대해 **Node Classification** 위해 **Attention** 메커니즘 사용

GAT의 장점

- 연산의 효율성**
 - Attention 가중치 계산 시 모든 이웃을 고려하지 않고 특정 벡터를 신경망에 통과시켜 계산
 - 그래프 크기가 커질수록 계산 복잡도 크게 감소
 - 병렬 처리 가능
- 노드의 차수(degree)에 무관한 적용 가능성**
 - Attention 메커니즘을 통해 이웃 노드들의 중요도를 학습
 - 노드의 차수와 관계없이 유연하게 적용 가능
 - 각 노드는 이웃 노드들에 대해 서로 다른 중요도(Weight) 할당
 - 그래프의 구조적 특성 반영 가능
- 귀납적 학습 가능성**
 - 귀납적 학습(Inductive Learning)이 가능한 모델
 - 학습 단계에서 보지 못한 데이터에 대해 일반화 가능
 - 새로운 그래프에 대해서도 예측 수행 가능
 - 새로운 그래프 데이터에 대해 높은 성능을 보임


GAT Architecture

GAT 모델의 주요 구성 요소 및 수식

$$a : \mathbb{R}^{F'} \times \mathbb{R}^{F'} \rightarrow \mathbb{R} \quad e_{ij} = a(\mathbf{W}\vec{h}_i, \mathbf{W}\vec{h}_j)$$



$$\alpha_{ij} = \text{softmax}_j(e_{ij}) = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}_i} \exp(e_{ik})}.$$

$$\alpha_{ij} = \frac{\exp \left(\text{LeakyReLU} \left(\vec{\mathbf{a}}^T [\mathbf{W}\vec{h}_i \| \mathbf{W}\vec{h}_j] \right) \right)}{\sum_{k \in \mathcal{N}_i} \exp \left(\text{LeakyReLU} \left(\vec{\mathbf{a}}^T [\mathbf{W}\vec{h}_i \| \mathbf{W}\vec{h}_k] \right) \right)}$$



GAT Architecture

Attention 메커니즘과 그래프 상 Multi-head Attention 예시



GAT Architecture

GAT (Graph Attention Network) 모델의 동작 프로세스 수식

1. 단일 헤드 그래프 어텐션 레이어에서 노드 i 의 새로운 특징 벡터 hi' 를 계산하는 과정

2. 다중 헤드 그래프 어텐션 레이어에서 노드 i 의 새로운 특징 벡터 hi' 를 계산하는 과정

K 개의 독립적인 어텐션 헤드 각각에 대해 동일한 과정을 수행한 후, 각 헤드의 출력을 연결(Concatenation)

3. 다중 헤드 그래프 어텐션 레이어의 출력을 평균 내어 노드 i 의 새로운 특징 벡터 hi' 를 계산하는 과정

각 어텐션 헤드의 출력을 평균낸 후, 활성화 함수

$$\vec{h}'_i = \sigma \left(\sum_{j \in \mathcal{N}_i} \alpha_{ij} \mathbf{W} \vec{h}_j \right). \quad \vec{h}'_i = \left\| \sigma \left(\sum_{j \in \mathcal{N}_i} \alpha_{ij}^k \mathbf{W}^k \vec{h}_j \right) \right\|_K \quad \vec{h}'_i = \sigma \left(\frac{1}{K} \sum_{k=1}^K \sum_{j \in \mathcal{N}_i} \alpha_{ij}^k \mathbf{W}^k \vec{h}_j \right)$$

Datasets

실험에 사용한 데이터셋 : Cora, Citeseer, Pubmed

Table 1: Summary of the datasets used in our experiments.

	Cora	Citeseer	Pubmed	PPI
Task	Transductive	Transductive	Transductive	Inductive
# Nodes	2708 (1 graph)	3327 (1 graph)	19717 (1 graph)	56944 (24 graphs)
# Edges	5429	4732	44338	818716
# Features/Node	1433	3703	500	50
# Classes	7	6	3	121 (multilabel)
# Training Nodes	140	120	60	44906 (20 graphs)
# Validation Nodes	500	500	500	6514 (2 graphs)
# Test Nodes	1000	1000	1000	5524 (2 graphs)

Datasets

Transductive Learning

- 표준 인용 네트워크 벤치마크 데이터셋 활용 (Cora, Citeseer, Pubmed)
- 각 노드는 문서를 나타내고, 에지는 인용 관계 표현
- 학습에는 클래스별 20개 노드만 사용하지만, 모든 노드의 특징 벡터에 접근 가능
- 1000개 테스트 노드와 500개 검증 노드로 성능 평가

Inductive Learning

- 단백질 상호작용 (Protein-Protein Interaction, PPI) 데이터셋 활용
- 서로 다른 인간 조직에 해당하는 24개 그래프로 구성 (20개 학습, 2개 검증, 2개 테스트)
- 테스트 그래프는 학습 중 관찰되지 않음을 전제
- 평균 노드 수는 2372개이며, 각 노드는 50개의 특징과 121개의 레이블 보유

Experimental Setup

Transductive Learning

- 2-layer GAT 모델 적용
 - 첫 번째 레이어: 8개 어텐션 헤드, 각 헤드는 8개 특징 계산
 - 두 번째 레이어: 1개 어텐션 헤드, 클래스 수에 해당하는 특징 계산
- L2 정규화 ($\lambda = 0.0005$), Dropout ($p = 0.6$) 적용
- Pubmed 데이터셋은 학습 예제 수가 적어 약간의 아키텍처 변경 필요

Inductive Learning

- 3-layer GAT 모델 적용
 - 처음 2개 레이어: 4개 어텐션 헤드, 각 헤드는 256개 특징 계산
 - 마지막 레이어: 6개 어텐션 헤드, 각각 121개 특징 계산 후 평균
- Skip connection 적용, 배치 크기는 2개 그래프
- 어텐션 메커니즘의 효과를 평가하기 위해 상수 어텐션 메커니즘
(모든 이웃에 동일한 중요도 할당) 적용 모델도 비교

Results - Transductive

Table 2: Summary of results in terms of classification accuracies, for Cora, Citeseer and Pubmed. GCN-64* corresponds to the best GCN result computing 64 hidden features (using ReLU or ELU).

<i>Transductive</i>			
Method	Cora	Citeseer	Pubmed
MLP	55.1%	46.5%	71.4%
ManiReg (Belkin et al., 2006)	59.5%	60.1%	70.7%
SemiEmb (Weston et al., 2012)	59.0%	59.6%	71.7%
LP (Zhu et al., 2003)	68.0%	45.3%	63.0%
DeepWalk (Perozzi et al., 2014)	67.2%	43.2%	65.3%
ICA (Lu & Getoor, 2003)	75.1%	69.1%	73.9%
Planetoid (Yang et al., 2016)	75.7%	64.7%	77.2%
Chebyshev (Defferrard et al., 2016)	81.2%	69.8%	74.4%
GCN (Kipf & Welling, 2017)	81.5%	70.3%	79.0%
MoNet (Monti et al., 2016)	81.7 ± 0.5%	—	78.8 ± 0.3%
GCN-64*	81.4 ± 0.5%	70.9 ± 0.5%	79.0 ± 0.3%
GAT (ours)	83.0 ± 0.7%	72.5 ± 0.7%	79.0 ± 0.3%

Results - Inductive

Table 3: Summary of results in terms of micro-averaged F_1 scores, for the PPI dataset. GraphSAGE* corresponds to the best GraphSAGE result we were able to obtain by just modifying its architecture. Const-GAT corresponds to a model with the same architecture as GAT, but with a constant attention mechanism (assigning same importance to each neighbor; GCN-like inductive operator).

<i>Inductive</i>	
Method	PPI
Random	0.396
MLP	0.422
GraphSAGE-GCN (Hamilton et al., 2017)	0.500
GraphSAGE-mean (Hamilton et al., 2017)	0.598
GraphSAGE-LSTM (Hamilton et al., 2017)	0.612
GraphSAGE-pool (Hamilton et al., 2017)	0.600
GraphSAGE*	0.768
Const-GAT (ours)	0.934 ± 0.006
GAT (ours)	0.973 ± 0.002

Results - Visualization

GAT 모델의 첫 번째 히든 레이어에서 계산된 피처 표현의 t-SNE 플롯




Figure 2: A t-SNE plot of the computed feature representations of a pre-trained GAT model's first hidden layer on the Cora dataset. Node colors denote classes. Edge thickness indicates aggregated normalized attention coefficients between nodes i and j , across all eight attention heads ($\sum_{k=1}^K \alpha_{ij}^k + \alpha_{ji}^k$).

Conclusion

- Graph Attention Networks (GATs) 제안
 - Masked Self-Attentional 레이어를 활용한 새로운 Convolution 기반 신경망
 - 계산 효율성, 서로 다른 크기의 이웃에 대한 dynamic attention, 귀납적 학습 등 이점
- Transductive 및 Inductive 노드 분류 벤치마크에서 최고 성능 달성 또는 동등한 성능
- 향후 연구 방향
 - 대용량 배치 처리를 위한 개선
 - 모델 해석 가능성 향상을 위한 어텐션 메커니즘 활용
 - 그래프 분류 작업으로 확장
 - 에지 특징 통합을 통한 다양한 문제 해결